

Master-Architektur-Spezifikation: Algorithmischer Multi-Asset Trading-Bot (H1- Timeframe)

Zielsetzung: Entwicklung eines hochgradig optimierten, wissenschaftlich fundierten Trading-Algorithmus für 100 Assets aus verschiedenen Anlageklassen (Forex, Krypto, Aktien, Indizes, Rohstoffe). Der Bot basiert auf der Erkennung von Support/Resistance-Zonen, dynamischer Regime-Erkennung mittels Hidden Markov Models (HMM) und heuristischer Parameter-Optimierung.

Hinweis zur Skalierbarkeit: Die genaue Anzahl der HMM-Zustände sowie die finale Auswahl der Indikatoren in diesem Dokument dienen als fundierte Orientierung. Die endgültige Anzahl wird im Entwicklungsprozess durch mathematische Evaluierungsverfahren (wie AIC/BIC) und Backtesting-Ergebnisse datengetrieben festgelegt, um das absolute Optimum für das jeweilige Asset-Cluster zu finden.

Phase 1: Datenbasis & Infrastruktur

- **Datenquelle:** Broker Pepperstone via MetaTrader 5 (MT5) API in Python (MetaTrader5 Library).
 - **Timeframe:** H1 (1-Stunden-Kerzen) als optimaler Kompromiss aus statistischer Signifikanz (genügend Trades) und Rauschunterdrückung.
 - **Datenumfang:** Open, High, Low, Close, Tick-Volume (OHLCV). Historie idealerweise 3 bis 5 Jahre.
 - **Programmiersprache & Frameworks:** Python. Bibliotheken: pandas, numpy, hmmlearn (für Regime-Erkennung), scikit-optimize oder Optuna (für Bayes'sche Optimierung), vectorbt oder backtrader (für den Backtest).
-

Phase 2: Asset-Clustering (Bereits durchgeführt)

- **Konzept:** Die 100 Assets werden nicht als homogene Masse behandelt, sondern in ca. 12 Cluster unterteilt (z.B. basierend auf Volatilität, Trendstärke, Liquidität).
 - **Funktion im Bot:** Der Algorithmus nutzt das Cluster als primäre ID. Jedes Cluster erhält später seine eigenen, maßgeschneiderten HMM-Modelle und optimierten Indikator-Parameter.
-

Phase 3: Markterkennung via Hidden Markov Models (HMM)

Anstatt starrer Filter (wie "EMA 200") wird ein probabilistisches Modell genutzt, um den verborgenen Zustand (Hidden State) des Marktes in Echtzeit zu berechnen.

- **Input-Features für das HMM:** Stündliche logarithmische Renditen (Log>Returns) und stündliche Volatilität (z.B. basierend auf der Average True Range).
 - **Anzahl der Zustände (Regime):** Um die maximale Präzision zu erreichen, testen wir das HMM nicht nur auf 2, sondern auf **3 bis 4 Zustände**.
 - *Beispiel-Klassifikation:* State 0 (Seitwärts/Ruhig), State 1 (Starker Aufwärtstrend), State 2 (Starker Abwärtstrend), State 3 (Hohe Volatilität/Crash-Gefahr).
 - **Mathematische Bestimmung der optimalen Zustands-Anzahl:** Wir raten die Anzahl nicht. Die ideale Anzahl der Zustände pro Cluster wird über das **Akaike-Informationskriterium (AIC)** oder das **Bayesian Information Criterion (BIC)** berechnet. Das Modell mit dem niedrigsten BIC-Wert gewinnt.
 - **Output:** Das HMM liefert für jede H1-Kerze eine Wahrscheinlichkeitsverteilung (z.B. 85% Wahrscheinlichkeit für State 0).
-

Phase 4: Der Indikatoren-Baukasten (Hyperparameter-Raum)

Um dem Optimizer ein breites, aber logisch getrenntes Arsenal zur Verfügung zu stellen, werden die Indikatoren in exklusive Kategorien (Slots) unterteilt. Der Algorithmus darf pro Cluster und pro Regime *jeweils nur einen* Indikator aus einer Kategorie wählen, um Overfitting (Fluch der Dimensionalität) zu verhindern.

Kategorie A: Zonen-Identifikation (Support/Resistance)

- *Pivot Points* (Standard, Fibonacci & Woodie)
- *Bollinger Bands* (Dynamische S/R durch Standardabweichung)
- *Ichimoku Kinkohyo* (Die "Kumo"-Wolke als dynamische Support-Zone)
- *Keltner Channels* (ATR-basierte Bänder)
- *VWAP* (Volume Weighted Average Price - inkl. Standardabweichungs-Bänder)

Kategorie B: Signal-Bestätigung (Momentum / Abpraller)

- *RSI* (Klassisch)
- *Adaptiver RSI* (Eigenentwicklung: Periodenlänge passt sich dynamisch an die aktuelle ATR an)
- *MACD* (Moving Average Convergence Divergence)
- *Stochastic Oscillator*
- *Money Flow Index (MFI)* (Zieht zusätzlich das Volumen zur Bestätigung heran)

Kategorie C: Trend-Filter (Optional, falls HMM Unterstützung braucht)

- *EMA (Exponential Moving Average)* (Schnittpunkte, z.B. 50er und 200er)
 - *ADX (Average Directional Index)* (Misst rein die Stärke des Trends, nicht die Richtung)
 - *Parabolic SAR* (Aus der Literatur: für Trailing-Stops und Trendwechsel)
-

Phase 5: Die Trading- & Ausführungs-Logik

Die Strategie passt sich an das vom HMM gemeldete Regime an:

1. **Regime "Seitwärts/Ruhig"**: S/R-Mean-Reversion-Logik wird aktiviert. Preis prallt an Zone (Kategorie A) ab, Momentum (Kategorie B) bestätigt die Gegenbewegung. Trade wird ausgeführt.
 2. **Regime "Trend"**: S/R-Mean-Reversion wird blockiert (da S/R-Zonen hier durchbrochen werden). Stattdessen Wechsel auf Breakout-Strategie oder Pause.
 3. **Risikomanagement (Dynamic Execution)**: * *Stop-Loss (SL)*: Darf niemals starr sein (z.B. "10 Pips"). Der SL wird auf Basis eines Vielfachen der aktuellen ATR gesetzt (z.B. 1.5 * ATR unter dem Pivot Point), um der Volatilität Raum zu geben.
 - *Take-Profit (TP)*: Entweder festes Risk-Reward-Ratio (z.B. 1:2) oder dynamischer Ausstieg (z.B. wenn Preis das gegenüberliegende Bollinger Band erreicht).
-

Phase 6: Parameter-Optimierung (Bayesian Optimization)

- **Methode**: Bayes'sche Optimierung (übertrifft Grid Search und Genetische Algorithmen an Effizienz, wie in der Literatur belegt).
 - **Der Suchraum**: Der Optimizer sucht für *jedes Cluster* und *jedes HMM-Regime* die ideale Kombination aus Kategorie A, B, C und den jeweiligen Parametern (z.B. RSI-Periode zwischen 5 und 21).
 - **Zielfunktion (Objective Function)**: Es wird nicht primär auf den höchsten Netto-Profit optimiert (das führt zu riskanten Strategien), sondern auf Risiko-adjustierte Metriken wie die **Sharpe Ratio** oder den **Sortino Ratio** (Maximierung des Profits bei gleichzeitiger Minimierung des maximalen Drawdowns).
-

Phase 7: Validierung zur Vermeidung von Overfitting

Um den akademischen Standard zu garantieren und Curve-Fitting vollständig auszuschließen, wird der gesamte Optimierungsprozess durch eine strenge Out-of-Sample-Testung validiert.

- **Methode**: Walk-Forward-Analysis (WFA) / TimeSeriesSplit.

- **Ablauf:** 1. *Training/Optimierung* auf Zeitraum T1 (z.B. Jahre 1-2). 2. *Blinder Test* der gefundenen Parameter auf Zeitraum T2 (z.B. Jahr 3). 3. Verschieben des Fensters: Training auf Jahre 2-3, blinder Test auf Jahr 4.
- **Erfolgskriterium:** Wenn die zusammengesetzte Equity-Kurve der isolierten, blinden Testphasen (Out-of-Sample) stabil nach oben zeigt und eine Sharpe Ratio von idealerweise > 1.0 aufweist, gilt der Algorithmus als robust und live-tauglich.